

## Ciclo Menstrual e Desempenho Físico: Modelo de Aprendizado de Máquina para Otimização de Treinamento Físico em Mulheres\*

Anna Luiza Alves D. Silva, Gustavo Costa<sup>1</sup>

### Resumo

A variabilidade do ciclo menstrual impacta significativamente o desempenho físico, saúde e bem-estar das mulheres, porém as prescrições de exercícios raramente consideram essas flutuações, gerando desconforto, riscos de lesão e desigualdade no esporte – especialmente entre não atletas, grupo no qual 25% reportam limitações severas. Este estudo propõe desenvolver um modelo de machine learning para personalizar treinos conforme fases do ciclo menstrual e características individuais, com objetivos específicos de: i) identificar perfis de resposta ao exercício via técnicas de clusterização; ii) prever desempenho físico mediante variáveis hormonais e fisiológicas; iii) validar um sistema de recomendações adaptativas. A metodologia baseou-se na geração de dados sintéticos (N=1.200 perfis) simulando parâmetros demográficos, hormonais, sintomas menstruais e métricas de desempenho, seguidos de aplicação de algoritmos de agrupamento (K-means) e modelagem preditiva (XGBoost).

**Palavras-chave:** Machine Learning. Saúde. Esporte. Dados. Menstruação.

\* Artigo apresentado à Revista Abakos

<sup>1</sup> Graduação em Ciência de Dados e Inteligência Artificial - PUC Minas, Brasil– annaluizabh10@gmail.com, gus-tavocosta.ds09@gmail.com

## 1 INTRODUÇÃO

O ciclo menstrual é um processo fisiológico complexo do organismo feminino que pode influenciar diversos aspectos durante a vida das mulheres, incluindo a prática de exercícios físicos. Estudos mostram que um quarto da população feminina é afetado por problemas decorrentes do ciclo menstrual e que afetam essas mulheres em diversos aspectos de suas vidas, por exemplo, no âmbito físico, emocional e social, podendo se estender ao ambiente de trabalho (FRASER I.S.; PETRAGLIA, 2015). Ademais, é fundamental possuir o domínio das nuances do ciclo menstrual pois isso configura-se como elemento-chave para a compreensão da saúde reprodutiva e a promoção de um bem-estar integral que abrange os diferentes aspectos supracitados da mulher (T SAMPEI M, 2020). De acordo com o estudo (MCNULTY KIRSTY JAYNE ELLIOTT-SALE, 2020), há quatro fases no ciclo menstrual que são o período menstrual, a fase folicular, a fase de ovulação e a fase lútea, respectivamente. O prazo de cada fase é algo individual de cada mulher e altera-se com o tempo. Para mulheres eumenorreicas, isto é, com um ciclo menstrual regular, o prazo varia de 21 a 35 dias, sendo que a contagem inicial se dá a partir do primeiro dia de uma menstruação até o primeiro dia da menstruação seguinte. Para um ciclo regular, a fase de menstruação dura entre três a cinco dias, a fase lútea em média de quatorze dias assim como a fase folicular (REES MARGARET; RAVNIKAR, 2005). Todavia, esse padrão não é único para todas as mulheres, há uma variabilidade muito grande de pessoa para pessoa podendo ter uma duração mais curta ou mais longa (REES MARGARET; RAVNIKAR, 2005). A menstruação está presente no organismo de uma mulher até que ela alcance a menopausa, que ocorre geralmente ao final dos 50 anos de idade (REES MARGARET; RAVNIKAR, 2005), mas também está sujeita a variabilidade e características de cada indivíduo. Para que um ciclo seja considerado irregular, ele precisa estar fora dos intervalos regulares; em outras palavras, não há um padrão visível na variação de um ciclo para o outro (REES MARGARET; RAVNIKAR, 2005).

Um ciclo menstrual irregular não significa que está incorreto ou que gera danos ao organismo da mulher na maioria das vezes. Ter o status de irregular significa, na prática, que alguns fatores influenciaram no prazo de duração das diferentes fases e podem ser entendidos como: alterações hormonais, utilização de métodos contraceptivos, estresse, exercícios de resistência e variação de peso (MUNRO MALCOLM G.; FRASER., 2012). Por outro lado, em alguns casos a irregularidade pode configurar-se como insuficiência precoce ou síndrome do ovário policístico (REGO, 2023). Somada a isso, os ciclos irregulares podem prejudicar a gravidez devido à incerteza da ovulação da mulher. Seguindo por esse raciocínio, a irregularidade menstrual pode também comprometer o planejamento esportivo e a adaptação fisiológica ao exercício. Mulheres com ciclos irregulares frequentemente enfrentam desafios como flutuações imprevisíveis de energia, alterações na termorregulação e oscilações na recuperação muscular, fatores que impactam diretamente o desempenho atlético (CUNHA et al., 2021). Por exemplo, em esportes de endurance, a desidratação acelerada durante a fase lútea, comum em ciclos irregulares, pode reduzir a eficiência metabólica em até 15% (CUNHA et al., 2021).

Essa heterogeneidade biológica de cada mulher ressalta a necessidade de formular abordagens personalizadas. Nesse contexto, técnicas de aprendizado de máquina surgem como ferramentas promissoras para encontrar padrões ocultos nos dados multidimensionais (hormonais, sintomas, desempenho físico) e prever respostas individuais personalizadas ao exercício. Por exemplo, algoritmos de clusterização como o k-means podem identificar subgrupos de mulheres com perfis semelhantes (ex: alta sensibilidade à fase folicular), permitindo prescrições de treino adaptativas à realidade de cada mulher.

## **1.1 Pergunta de Pesquisa**

Como prever e gerenciar os impactos da variabilidade do ciclo menstrual (regular ou irregular) na saúde, bem-estar e desenvolvimento físico de mulheres utilizando abordagens de aprendizado de máquina?

## **1.2 Hipóteses**

- i. Algoritmos de clusterização (ex.: k-means, delta-trimax) são capazes de identificar subgrupos de mulheres com perfis hormonais e de resposta ao exercício semelhantes, gerando recomendações de treino adaptativas que otimizam o desempenho e reduzem riscos de lesão.
- ii. A aplicação de técnicas de aprendizado de máquina permite prever com precisão as variações no desempenho físico de mulheres nas diferentes fases do ciclo menstrual, possibilitando a prescrição de treinos personalizados.
- iii. Mulheres com ciclos irregulares apresentam maior variabilidade no desempenho físico em comparação àquelas com ciclos regulares.

## **1.3 Justificativas**

A pesquisa proposta surge para enfrentar um desafio negligenciado na saúde feminina: os impactos do ciclo menstrual no desempenho esportivo e no bem-estar de mulheres não atletas. Enquanto a relação entre menstruação e alto rendimento físico tem sido parcialmente explorada em atletas de elite, a grande maioria das mulheres —que pratica exercícios sem orientação personalizada— não recebem destaque em estudos científicos. Essa lacuna não apenas limita o entendimento acadêmico sobre as variações individuais no ciclo menstrual, mas também auxilia na permanência de desigualdades na prática esportiva, onde muitas mulheres enfrentam desconforto, desmotivação ou até mesmo riscos de lesão por falta de adaptação aos seus perfis hormonais.

A inovação deste trabalho está na integração entre aprendizado de máquina (ML) e fisi-

ologia menstrual, criando uma abordagem criativa para agrupar mulheres com base em dados multidimensionais. A heterogeneidade biológica feminina exige soluções personalizadas, e é aqui que técnicas de ML, como algoritmos de clusterização (ex Delta-TriMax), se mostram promissoras: ao identificar padrões ocultos, elas podem classificar subgrupos com características semelhantes (por exemplo, mulheres com maior sensibilidade à fase folicular ou lútea) e, assim, gerar recomendações de treino adaptativas. Essa personalização não só otimiza resultados esportivos, mas também reduz barreiras que afastam as mulheres da atividade física, como dor, fadiga extrema ou desregulação hormonal agravada por exercícios mal dosados.

Além do avanço científico, a pesquisa possui um impacto social direto: cerca de 25% das mulheres sofrem com limitações severas devido ao ciclo menstrual (FRASER I.S.; PETRAGLIA, 2015). Ao desenvolver um método acessível para prescrição de exercícios adaptados, este estudo contribui para a equidade no esporte, o autoconhecimento corporal e a prevenção de complicações relacionadas a treinos inadequados que, em larga escala, podem reduzir custos em saúde pública e melhorar a qualidade de vida.

## **1.4 Objetivo Geral**

Investigar a relação entre ciclo menstrual e desempenho em exercícios físicos, desenvolvendo um modelo baseado em machine learning para personalização de treinos adaptado às características individuais de cada mulher.

### ***1.4.1 Objetivos Específicos***

- i. Coletar e integrar dados multidimensionais (hormonais, fisiológicos, comportamentais) de mulheres em diferentes fases do ciclo menstrual
- ii. aplicar técnicas de aprendizado não supervisionado para identificar perfis de mulheres que possuem características semelhantes de adaptação à exercícios
- iii. validar um sistema de recomendação de treinos que considere a fase menstrual e as particularidades individuais.

## **2 TRABALHOS RELACIONADOS**

O estudo de (CUNHA et al., 2021) realizou uma revisão rápida da literatura para investigar os efeitos do ciclo menstrual no desempenho físico, analisando 14 artigos publicados entre 2000 e 2019. Os resultados indicaram que, embora 35,7% dos estudos tenham identificado melhor desempenho em exercícios de alta intensidade e curta duração (e.g., força máxima e potência) durante fases com maior concentração de hormônios ovarianos (como estrogênio

e luteinizante), a maioria (64,3%) não encontrou diferenças significativas entre as fases do ciclo. Os autores destacaram a inconsistência metodológica entre os trabalhos, especialmente quanto à definição das fases menstruais e aos protocolos de exercício, além de reforçarem a necessidade de avaliações individualizadas para atletas. Essas lacunas apontadas na literatura convencional justificam a proposta do presente estudo, que utiliza modelos de machine learning para personalizar o treinamento físico, considerando não apenas as variações hormonais, mas também fatores individuais como resposta metabólica, histórico de desempenho e adaptações fisiológicas das mulheres.

Complementando essa discussão, o trabalho de (MCNULTY KIRSTY JAYNE ELLIOTT-SALE, 2020) apresenta uma revisão sistemática e meta-análise abrangente que investigou os efeitos das fases do ciclo menstrual no desempenho físico de mulheres eumenorreicas. A análise incluiu dados de 78 estudos, sendo que 51 foram elegíveis para a meta-análise pareada e 73 para a meta-análise de rede, totalizando uma das revisões mais completas sobre o tema até o momento. Os resultados indicaram uma redução trivial no desempenho durante a fase folicular inicial, com um tamanho de efeito combinado mediano de -0,06, e destacaram que essa fase apresentou o menor valor de SUCRA (30%), sugerindo maior probabilidade de desempenho inferior nessa etapa do ciclo. Apesar da robustez metodológica, os autores apontam que a variabilidade entre os estudos e a qualidade moderada das evidências dificultam a formulação de recomendações generalizadas. Assim, reforçam a importância de estratégias individualizadas, alinhando-se à proposta deste estudo de utilizar modelos de aprendizado de máquina para otimizar o treinamento físico com base nas respostas específicas de cada mulher ao longo do ciclo menstrual.

Além das variações hormonais, condições clínicas associadas ao ciclo menstrual — como o sangramento menstrual intenso (SMI) — podem influenciar diretamente o desempenho físico e a capacidade de treinamento em mulheres. (FRASER I.S.; PETRAGLIA, 2015) investigaram a prevalência e o impacto do SMI em uma amostra de 4.506 mulheres europeias, identificando que 27,2% apresentavam sintomas característicos dessa condição, mas quase metade (46%) nunca havia consultado um médico. Entre as diagnosticadas, 63% tinham deficiência de ferro ou anemia ferropriva, e apenas 46,1% receberam tratamento adequado. Esses achados destacam não apenas a subnotificação do SMI, mas também seus efeitos negativos na saúde metabólica e cardiovascular, fatores críticos para a resistência física e a recuperação pós-exercício. A incorporação de variáveis clínicas como anemia e perda sanguínea excessiva em modelos de machine learning pode aprimorar a personalização do treinamento, ajustando cargas e recuperação conforme as necessidades individuais, especialmente em mulheres com alterações menstruais significativas.

As variações do ciclo menstrual e da temperatura corporal basal (TCB) ao longo da vida e em diferentes contextos ambientais foram sistematicamente analisadas por (T SAMPEI M, 2020) em um estudo de coorte retrospectivo com dados de 6 milhões de ciclos de 310.000 mulheres japonesas. Os resultados revelaram que o comprimento médio do ciclo menstrual aumenta dos 15 aos 23 anos, diminui progressivamente até os 45 anos e volta a crescer após

essa idade, enquanto a temperatura da fase lútea atinge seu pico aos 29 anos e declina após os 42 anos. Além disso, os autores identificaram uma correlação significativa entre a temperatura ambiental e a TCB (tanto na fase folicular quanto na lútea), embora nenhuma associação tenha sido observada com a duração do ciclo. Esses achados, obtidos por meio de autorrelato em aplicativos móveis, destacam a influência de fatores etários e climáticos na dinâmica menstrual, reforçando a necessidade de personalizar estratégias de treinamento físico com base não apenas em características hormonais, mas também em variáveis ambientais e individuais. O contexto de (T SAMPEI M, 2020) sustenta a proposta deste estudo de utilizar modelos de machine learning para otimizar o desempenho físico, incorporando padrões de TCB e sazonalidade como parâmetros preditivos adicionais.

O livro *The Abnormal Menstrual Cycle*, editado por (REES MARGARET; RAVNI-KAR, 2005), oferece uma base sólida sobre os aspectos fisiológicos e patológicos do ciclo menstrual, destacando como alterações hormonais podem impactar diversos sistemas do corpo feminino. A obra aborda de forma abrangente distúrbios como amenorreia, oligomenorreia e dismenorreia, enfatizando que irregularidades menstruais podem estar associadas a desequilíbrios hormonais que afetam não apenas a saúde reprodutiva, mas também a capacidade funcional e o bem-estar geral das mulheres. Além disso, o livro ressalta que o entendimento detalhado das fases do ciclo e de suas variações individuais é essencial para intervenções clínicas mais eficazes. Esses fundamentos teóricos reforçam a importância de se considerar as particularidades do ciclo menstrual na prescrição de atividades físicas.

O estudo de (LI et al., 2021) demonstra o potencial dos algoritmos de aprendizado de máquina na predição de condições clínicas em mulheres, ao utilizar registros eletrônicos de saúde (EHR) para prever o risco de desenvolvimento de pré-eclâmpsia (PE). A pesquisa analisou 3759 casos de gestantes, empregando modelos como regressão logística, random forest, support vector machine e XGBoost, sendo este último o mais eficaz, com acurácia de 92,0% e área sob a curva ROC (auROC) de 0,955. As variáveis mais relevantes para a predição foram a glicemia em jejum, a pressão arterial média e o índice de massa corporal. Além disso, os autores propuseram um modelo simplificado baseado em apenas oito perguntas que poderiam ser respondidas pela própria paciente, ainda mantendo boa acurácia (auROC = 0,83). Este trabalho evidencia a aplicabilidade de técnicas de machine learning em contextos clínicos e reprodutivos, reforçando a viabilidade do presente estudo ao propor a utilização de modelos preditivos personalizados no contexto do ciclo menstrual e desempenho físico feminino.

O trabalho de (CHOUDHARY; THAKUR, 2025) apresenta uma revisão abrangente sobre os avanços da inteligência artificial na saúde da mulher, com foco especial nas abordagens de deep learning e processamento de linguagem natural. A pesquisa destaca como essas tecnologias têm contribuído significativamente para a detecção precoce de doenças, tratamentos personalizados e cuidados preventivos escaláveis, especialmente no contexto de câncer ginecológico, saúde materna e distúrbios reprodutivos como a Síndrome dos Ovários Policísticos (SOP). O estudo enfatiza que, apesar do progresso tecnológico entre 2018 e 2023, desafios como a falta de diversidade nos conjuntos de dados, a opacidade dos modelos e as dificulda-

des de implementação prática ainda limitam o alcance das soluções baseadas em IA. A revisão reforça a necessidade urgente de estratégias acessíveis e eficazes, especialmente em regiões subatendidas, consolidando a importância de inovações tecnológicas na promoção da saúde da mulher em nível global.

Ademais, no estudo (REGO, 2023) os autores buscaram construir modelos de séries temporais com a utilização de algoritmos de aprendizado de máquina (como ARIMA e redes LSTM, ideais para séries longas de dados) para prever a duração de ciclos regulares e irregulares, utilizando dados sintéticos robustos que permitem captar diferentes variações de um ciclo menstrual real. Embora a pesquisa não utilize técnicas de clusterização, ela demonstra o potencial do aprendizado de máquina para melhorar o planejamento de aspectos críticos da saúde feminina, como fertilidade e integração de atividades físicas. Enquanto (REGO, 2023) priorizam a previsão de ciclos, este estudo busca identificar padrões heterogêneos entre mulheres (atletas ou não) por meio de técnicas de clusterização para a construção de treinos físicos personalizados para mulheres.

### **3 METODOLOGIA**

Este estudo adotará uma abordagem quantitativa, combinando técnicas descritivas e preditivas para investigar a relação entre o ciclo menstrual e o desempenho físico em mulheres. Dada a complexidade e os desafios éticos e logísticos da coleta de dados primários longitudinais que abrangem o ciclo menstrual e o desempenho físico, a pesquisa utilizará dados sintéticos. Essa estratégia visa garantir uma base de dados robusta e diversificada, capaz de simular a individualidade presente nos ciclos menstruais e suas implicações na atividade física, focando na validação do conceito e na demonstração da capacidade do modelo de aprendizado de máquina.

#### **3.1 Desenho do Estudo**

O estudo será do tipo transversal, focado no desenvolvimento de um modelo de aprendizado de máquina. A metodologia principal que será abordada é a geração de dados sintéticos e a aplicação de técnicas de clustering não supervisionado, modelos preditivos supervisionados e análises estatísticas para explorar as relações identificadas.

#### **3.2 Geração de Dados Sintéticos**

A base de dados será inteiramente composta por dados sintéticos, gerados cuidadosamente para representar as características e variações esperadas de um conjunto de dados real sobre ciclo menstrual e desempenho físico. A geração desses dados envolverá as seguintes

simulações:

- **Características Demográficas:** Idade, peso e altura, distribuídos conforme perfis populacionais já conhecidos.

- **Ciclo Menstrual:** Duração do ciclo e de suas fases (folicular, lútea, menstrual), alterações hormonais e a ocorrência de sintomas pré-menstruais e menstruais. Todas essas informações geradas seguirão padrões descritas na literatura científica e estudos da área da saúde.

- **Desempenho Físico:** Diferentes métricas de desempenho serão incorporadas ao presente estudo, por exemplo o tipo de exercício praticado, a frequência, percepção de esforço, carga utilizada e o tempo de recuperação.

- **Variabilidade Individual:** Será introduzido a aleatoriedade controlada para gerar o conjunto de dados sintéticos para garantir a heterogeneidade presente na população feminina.

Esses dados gerados visam representar os diferentes padrões fisiológicos presentes nas mulheres, embora seja importante salientar que os resultados do modelo serão, em um primeiro momento, para validação de conceito e requerem futura validação com dados reais.

### 3.3 Participantes e Critérios de Elegibilidade

Para fins de modelagem, os perfis das participantes serão construídos com base nos seguintes critérios, que representariam os critérios de inclusão e exclusão se fosse um estudo com dados reais:

#### 3.3.1 *Perfis de Inclusão:*

- Mulheres com idade entre 18 e 50 anos.
- Praticantes de exercícios com uma frequência de pelo menos três vezes na semana.
- Mulheres com ciclo menstrual regular
- Mulheres com ciclo menstrual irregular (diagnósticos como síndrome dos ovários policísticos ou endometriose avançada), nesse caso, possuirão uma observação à respeito do diagnóstico.

#### 3.3.2 *Perfis de Exclusão:*

- Mulheres gestantes.
- Mulheres em menopausa.



### 3.4 Coleta de Dados

A coleta de dados será realizada por meio da geração algorítmica das informações que seriam obtidas por meio de questionários direcionados à mulheres que praticam exercícios físicos regularmente em um estudo primário.

### 3.5 Pré-processamento dos Dados

Após a geração, os dados sintéticos serão submetidos a um rigoroso processo de pré-processamento. Técnicas como normalização (padronização por z-score) serão aplicadas para escalar as variáveis numéricas. Para o tratamento de dados faltantes (simulados para refletir os ruídos de coleta), será utilizada a imputação por média, mediana, interpolação ou regressão com base em uma análise criteriosa individual. Variáveis categóricas serão codificadas utilizando label encoding e one-hot encoding para serem compatíveis com os algoritmos de aprendizado de máquina.

### 3.6 Análise de Dados e Aplicação de Aprendizado de Máquina

A análise de dados ocorrerá em três etapas principais:

1. **Agrupamento (Clustering):** Algoritmos de clustering não supervisionados, como K-Means ou Delta-TriMax, serão utilizados para identificar grupos de mulheres com perfis semelhantes em relação à resposta ao exercício físico durante diferentes fases do ciclo menstrual. A qualidade dos agrupamentos será avaliada por métricas como o Silhouette Score.
2. **Modelagem Preditiva:** Modelos de aprendizado de máquina supervisionados, como Random Forest e XGBoost, serão treinados para prever o desempenho físico com base nas características individuais das participantes e na fase do ciclo menstrual. Os dados serão divididos em conjuntos de treino (70%) e teste (30%). A validação cruzada (k-fold cross-validation) será utilizada para garantir a robustez do modelo. As métricas de avaliação incluirão a acurácia, precisão, sensibilidade e F1-Score. Além disso, será realizada a otimização de hiperparâmetros para cada modelo.
3. **Análises Estatísticas:** Análises estatísticas complementares serão feitas para comparar o desempenho físico entre as diferentes fases do ciclo menstrual conforme a distribuição dos dados. Correlações de Spearman serão utilizadas para verificar a relação entre sintomas menstruais específicos e respostas ao exercício.

### **3.7 Considerações Éticas**

Por se tratar de um estudo baseado em dados sintéticos e não envolvendo diretamente seres humanos, o protocolo dispensa a submissão a um Comitê de Ética em Pesquisa (CEP) para aprovação. Entretanto, o desenvolvimento do modelo será conduzido com rigor e transparência, assegurando que os dados sintéticos reflitam de forma ética e responsável as características da população feminina, sem gerar viés ou representações equivocadas.

4 CRONOGRAMA DE ATIVIDADES




Figura 1 – Cronograma do projeto em orientação vertical.

## Referências

- CHOUDHARY, Jyoti; THAKUR, Madhuri. Advances in ai for women's healthcare: A review of deep learning and nlp approaches. In: **2025 3rd International Conference on Intelligent Data Communication Technologies and Internet of Things (IDCIoT)**. [S.l.: s.n.], 2025. p. 289–294.
- CUNHA, Milena et al. Efeito do ciclo menstrual no desempenho em exercício físico: uma revisão rápida da literatura. **Revista Brasileira de Prescrição e Fisiologia do Exercício**, v. 15, p. 194–202, 11 2021.
- FRASER I.S., Mansour D. Breymann C.-Hoffman C. Mezzacasa A.; PETRAGLIA, F. Prevalence of heavy menstrual bleeding and experiences of affected women in a european patient survey. **International Journal of Gynecology Obstetrics**, v. 128, n. 3, p. 196–200, 2015.
- LI, Yi xin et al. Novelelectronic health records applied for prediction of pre-eclampsia: Machine-learning algorithms. **Pregnancy Hypertension**, v. 26, p. 102–109, 2021. ISSN 2210-7789. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2210778921005274>>.
- MCNULTY KIRSTY JAYNE ELLIOTT-SALE, Eimear Dolan Paul Alan Swinton Paul Ansdell Stuart Goodall Kevin Thomas Kirsty Marie Hicks Kelly Lee. The effects of menstrual cycle phase on exercise performance in eumenorrheic women: A systematic review and meta-analysis. **Sports Med**, v. 136, n. 4, p. 1813–1827, 2020.
- MUNRO MALCOLM G., Hilary OD Critchley; FRASER., Ian S. The figo systems for nomenclature and classification of causes of abnormal uterine bleeding in the reproductive years: who needs them? **American journal of obstetrics and gynecology**, v. 207, n. 4, p. 259–265, 2012.
- REES MARGARET, Sally Louise Hope; RAVNIKAR, eds Veronica A. **The abnormal menstrual cycle**. [S.l.]: CRC Press, 2005.
- REGO, Rosana C. B. Predictive modeling of menstrual cycle length: A time series forecasting approach. **arXiv preprint**, 2023.
- T SAMPEI M, Saito K-Honda Y Okazaki Y Arata N Narumi K Morisaki N Ishikawa T Narumi S Tatsumi. Age-dependent and seasonal changes in menstrual cycle length and body temperature based on big data. **OBSTETRICS GYNECOLOGY**, v. 136, n. 4, p. 666–674, 2020.